

# Benchmark RAG jurídico

Comparación reproducible de fidelidad factual sobre 1.000 decretos de holdout.

## Executive Summary

- **Mejor punto observado: C15.** Alcanzó **86.29%** de fidelidad factual extremo a extremo con embedding 4B, RAG 8192 y Ollama 16384; completó 1000/1.000 casos.
- **No hay una victoria amplia dentro de 4B.** Las mejores corridas forman una meseta cercana a 86%. Frente a C01, C15 mejora 0.24 puntos, con IC95% [-0.02; 0.49], por lo que esa diferencia no es concluyente.
- **Mejor 0.6B: C19.** Logró 85.85% con RAG 16384 y Ollama 32768. El 4B líder lo supera por 0.43 puntos (IC95% [0.11; 0.76]).
- **Decisión recomendada:** usar C15 como candidata de calidad y confirmar una muestra jurídica humana antes de fijarla en producción. C09 queda fuera del ranking porque solo cubre 103/1.000 casos.

Source: Resumen recalculado de las 19 corridas

Table: read\_csv\_auto


## Qué mide el gráfico

**Accuracy** es una cobertura factual automática extremo a extremo de 0 a 100: compara el borrador con un caché congelado de hechos extraídos de los PDFs y unido por ``case_number``, nombre, SHA-256 y hash del prompt. Los fallos y faltantes valen cero. El prompt solo define qué datos del PDF fueron revelados al sistema; no se usa como verdad de referencia. Precision **penaliza normas, fechas, plazos, expedientes y referencias de artículos adicionales**; Recall\*\*\* mide cuáles de esos identificadores se recuperaron. No detectan toda invención semántica. El asterisco indica que son métricas automáticas, no una evaluación jurídica humana.

Source: Resumen recalculado de las 19 corridas

Table: read\_csv\_auto

## Fidelidad factual automática por configuración



Escala 0–100. C15 es el mayor valor observado; C09 es una corrida parcial y no participa del ranking.

## La calidad se estabiliza cerca de 86%

El aumento de contexto no mejora de forma monotonica. Con embedding 4B, RAG 8.192 y Ollama 16.384 produce el mayor valor observado (C15), pero C01, C02, C03, C14 y C16 permanecen estadisticamente muy próximos. En 0.6B, aumentar Ollama de 8.192 a 32.768 tampoco garantiza una mejora; la mejor combinación completa es C19. El principal deterioro no provino del tamaño de contexto sino de perfiles restrictivos que generaron fallos: C04 tuvo 16 y C06 tuvo 86.

**Source: Resumen recalculado de las 19 corridas**

Table: read\_csv\_auto

## Qué explica el puntaje de C15

Organismo 97.7%, objeto 83.4%, dependencia 96.5%, fecha/plazo 63.3%, normas 88.7%, artículos 89.2% y datos críticos 70.6%. Persona/cargo no se puntúa automáticamente porque el caché no contiene ese campo con cobertura suficiente.

Source: Resumen recalculado de las 19 corridas

Table: read\_csv\_auto

### Las 19 configuraciones y sus resultados

| CASO | MODELO | RAG   | OLLAMA | K  | POOL | SCORE | ÉXITO  | ACCURACY* | PRECISION* | RECALL* |
|------|--------|-------|--------|----|------|-------|--------|-----------|------------|---------|
| C01  | 4B     | 2048  | 8192   | 8  | 24   | 0.00  | 100.0% | 86.05%    | 43.34%     | 56.71%  |
| C02  | 4B     | 4096  | 16384  | 8  | 24   | 0.00  | 100.0% | 86.05%    | 42.61%     | 56.62%  |
| C03  | 4B     | 8192  | 32768  | 8  | 24   | 0.00  | 100.0% | 86.05%    | 42.50%     | 56.80%  |
| C04  | 4B     | 4096  | 16384  | 5  | 15   | 0.65  | 98.4%  | 84.60%    | 43.26%     | 56.23%  |
| C05  | 0.6B   | 2048  | 8192   | 8  | 24   | 0.00  | 100.0% | 85.65%    | 44.89%     | 55.76%  |
| C06  | 0.6B   | 2048  | 8192   | 5  | 15   | 0.65  | 91.4%  | 78.58%    | 45.67%     | 51.99%  |
| C07  | 0.6B   | 3072  | 16384  | 12 | 36   | 0.00  | 99.9%  | 85.69%    | 44.47%     | 55.58%  |
| C08  | 0.6B   | 2048  | 8192   | 8  | 40   | 0.55  | 99.7%  | 85.46%    | 44.72%     | 55.54%  |
| C09  | 0.6B   | 1536  | 8192   | 3  | 12   | 0.60  | 10.1%  | 8.78%     | 53.89%     | 6.49%   |
| C10  | 4B     | 2048  | 16384  | 8  | 24   | 0.00  | 100.0% | 85.95%    | 43.01%     | 56.64%  |
| C11  | 4B     | 2048  | 32768  | 8  | 24   | 0.00  | 100.0% | 86.01%    | 43.38%     | 56.79%  |
| C12  | 0.6B   | 2048  | 16384  | 8  | 24   | 0.00  | 100.0% | 85.64%    | 44.70%     | 55.68%  |
| C13  | 0.6B   | 2048  | 32768  | 8  | 24   | 0.00  | 100.0% | 85.49%    | 44.70%     | 55.56%  |
| C14  | 4B     | 4096  | 16384  | 8  | 24   | 0.00  | 100.0% | 86.05%    | 42.89%     | 56.64%  |
| C15  | 4B     | 8192  | 16384  | 8  | 24   | 0.00  | 100.0% | 86.29%    | 42.94%     | 57.10%  |
| C16  | 4B     | 16384 | 16384  | 8  | 24   | 0.00  | 100.0% | 86.09%    | 42.62%     | 56.97%  |

| CASO | MODELO | RAG   | OLLAMA | K | POOL | SCORE | ÉXITO  | ACCURACY* | PRECISION* | RECALL* |
|------|--------|-------|--------|---|------|-------|--------|-----------|------------|---------|
| C17  | 0.6B   | 4096  | 32768  | 8 | 24   | 0.00  | 100.0% | 85.80%    | 44.02%     | 56.04%  |
| C18  | 0.6B   | 8192  | 32768  | 8 | 24   | 0.00  | 100.0% | 85.77%    | 44.28%     | 55.95%  |
| C19  | 0.6B   | 16384 | 32768  | 8 | 24   | 0.00  | 100.0% | 85.85%    | 44.30%     | 55.96%  |

\*Métricas automáticas; C09 es parcial y no participa del ranking.

## Recomendación para producción

1. **Candidata:** C15 — embedding 4B/2.560, RAG 8.192, Ollama 16.384, top\_k=8, pool 24 y score mínimo 0.
2. **Control humano:** revisar una muestra estratificada de los 1.000 pares PDF-output y adjudicar organismo, objeto, cargos, dependencia, plazos, normas, artículos y datos críticos.
3. **Regla de promoción:** confirmar que C15 conserve la ventaja en Accuracy jurídica y que no aumente las invenciones materiales. Hasta entonces, la recomendación es técnica y provisional.

**Source:** Resumen recalculado de las 19 corridas

Table: read\_csv\_auto

## Límites que cambian la interpretación

- Se analizaron 19 corridas, pero 18 configuraciones únicas: C02 y C14 son una réplica exacta de parámetros y sus resultados casi idénticos respaldan la repetibilidad.
- La referencia usada es un caché congelado de hechos extraídos de los 1.000 PDFs y ligado a sus SHA-256; la carpeta binaria original no está actualmente en este checkout.
- La extracción automática no comprende por completo equivalencias jurídicas ni puede decidir por sí sola si una paráfrasis conserva todos los efectos legales.
- C09 es parcial (103/1.000) y se muestra para trazabilidad, pero no participa del ranking.
- F1 se conserva en los datos técnicos, pero se omite del reporte ejecutivo porque no agrega una decisión distinta a Precision y Recall para esta audiencia.